Relatório de Evolução do Projeto — ChargeGrid AI Assistant

EV Challenge GoodWe | Sprint 04

1. Resumo da Evolução

O projeto evoluiu de um assistente de chat simples para um sistema de **RAG (Retrieval-Augmented Generation) Medido e Confiável**.

- **Sprints 1 e 2:** Foco em planejamento e implementação de um chatbot básico com prompts iniciais.
- **Sprint 03:** Refatoração para LangChain, introduzindo encadeamento conversacional e melhoria na gestão de memória.
- **Sprint 04 (Atual):** Implementação de infraestrutura de dados persistente com **ChromaDB**, vetorização semântica com `nomic-embed-text`, pipeline de grounding rigoroso, interface web via **Gradio** e, crucialmente, um framework de **avaliação quantitativa** (via fallback manual do RAGAS) para medir a fidelidade e relevância das respostas.

2. Pipeline RAG e Decisões Técnicas

2.1 Arquitetura de Dados

O pipeline segue o fluxo: `PDF` → `PyMuPDFLoader` → `RecursiveCharacterTextSplitter` → `ChromaDB` → `Retriever (Top-K)` → `LLM`.

2.2 Decisões de Chunking

Após testes comparativos, adotamos a configuração **800 caracteres com overlap de 100**.

- **Trade-off:** Chunks menores (512) isolavam melhor as perguntas do FAQ, mas fragmentavam os procedimentos técnicos do manual. Chunks maiores (1024) mantinham a coesão do manual, mas introduziam ruído ao agrupar múltiplas perguntas do FAQ em um único contexto, confundindo o LLM. O tamanho 800 provou ser o equilíbrio ideal para a natureza mista da base (Manual + FAQ).

2.3 Base de Conhecimento

A base foi expandida para incluir:

- Manuais técnicos de produtos HCA / HCA G2.
- FAQ de carregamento veicular.
- Portfólio institucional de produtos.

3. Tabela Comparativa Antes vs. Depois (OBRIGATÓRIA)

Esta tabela compara a versão original (Sprints 1/2) com a versão avaliada da Sprint 04.

Critério	Sprints 1/2 (Versão Original)	Sprint 04 (RAG Avaliado)	Impacto/Ganho
Método de Recuperação	Conhecimento interno do LLM / Contexto fixo	Busca Semântica via ChromaDB (Vetores)	↑ Precisão factual e redução de alucinações.
Citação de Fontes	Inexistente	Citação obrigatória `[Fonte: doc, pág. X]`	↑ Auditabilidade e confiança do usuário.
Grounding	Baixo (LLM inventava detalhes)	Rigoroso (Recusa se não houver evidência)	↑ Segurança; 100% de citações nas respostas.
Medição de Qualidade	Subjetiva (Testes manuais)	Quantitativa (Faithfulness / Relevancy)	↑ Capacidade de otimização baseada em dados.
Scores Médios	N/A (Não medido)	**0,568** (Média Geral)	Base establish para melhorias futuras.
Interface	Terminal / Notebook	Interface Web (Gradio)	↑ Usabilidade e acessibilidade.

4. Iterações e Ganho de Performance

Foram realizadas iterações focadas no ajuste do Prompt e na configuração de recuperação:

1. **Iteração 1 (Prompt v1.0):** Definição de persona e regras básicas de recusa.
2. **Iteração 2 (Prompt v2.0):** Introdução de blocos de `<prioridade>` e `<grounding>` numerados. Resultou em um ganho de **+0,007** na média de relevância, estabilizando a recusa de perguntas fora de escopo.

3. **Iteração 3 (Tuning de Recuperação):** Ajuste do limiar de relevância (`MIN_RELEVANCE = 0.20`). Identificou-se que 80% das falhas atuais são de *recuperação* (o documento existe, mas o retriever não o traz) e não de *geração*.

5. Problemas Encontrados e Soluções

Problema 1: Alucinações em Datas Institucionais

- **Cenário:** O modelo respondia que a GoodWe foi fundada em 2021 (data da fundação da filial USA) em vez de 2010 (global).
- **Solução:** Implementação do Prompt v2.0 com a instrução de "Citação obrigatória para cada afirmação factual". Isso forçou o modelo a olhar para o chunk específico, evidenciando a falha na recuperação do chunk de 2010 e evitando a resposta errada via recusa.

Problema 2: Falha na propagação de parâmetros de Chunking

- **Cenário:** O `iteration_runner.py` alterava o tamanho do chunk, mas o `chunking.py` continuava usando o valor fixo do import inicial.
- **Solução:** Refatoração da função `dividir_documentos` para aceitar parâmetros opcionais, permitindo que o motor de avaliação altere a estratégia de corte em tempo real sem reiniciar a aplicação.

6. Equipe e Divisão de Trabalho

Nome	RM	Tarefa Principal
Miguel Marcelo Alves Ramos de Oliveira	569467	Implementação do Pipeline RAG e ChromaDB
Felipe de Oliveira Doern	568798	Engenharia de Prompt e Avaliação RAGAS
Tom Stringasci Albuquerque Coelho de Morais	568844	Implementação da Interface Gradio
Eric dos Santos Mendes da Silva	569528	Documentação e Guardrails de Segurança
Ligia de Andrade Matheus	568973	Curadoria da Base de Conhecimento